




KRAFTON JUNGLE

AWS Immersion Day Amazon Bedrock 소개


AWS

AI의 발전



Amazon Bedrock 개요

파운데이션 모델 실행 및 사용자 지정 환경을 제공하는 완전 관리형 서비스



Amazon Bedrock 개요



Amazon Bedrock

보안 및 거버넌스

Guardrails
ID 및 인증
모델, 에이전트 접근 제어
Encryption
VPC, Privatelink

Model Catalog

amazon ANTHROPIC deepseek
Meta OpenAI Qwen ...

에이전트 레지스트리

런타임 메모리 브라우저 코드
인터프리터
Screw AI AI SDK

평가

LLM 심사
휴먼 인 더 루프

배포 / 구성

프롬프트 관리 교차 리전 추론
프롬프트 캐싱 서비스 티어 CMI

도구 레지스트리

MCP A2A 3rd Party

관측성

로깅
메트릭 및 모니터링
트레이싱
비용 추적

데이터 기반

벡터 스토어 그래프 스토어 학습 데이터 수집 파이프라인 BDA (IDP) 배치

RAG / 지식 기반

Amazon Bedrock 개요

도구

사용자 데이터 기반의 맞춤화

Knowledge Bases Bedrock Data Automation Fine tuning Model Distillation

실행 및 오케스트레이션

Agents Flows

개발자 경험

Prompt management IDE Prompt optimization

모델 선택 및 평가

기본 파운데이션 모델

amazon ANTHROPIC Meta Luma stability.ai
AI21labs cohere MISTRAL AI OpenAI Qwen deepseek

추가 모델

Bedrock Marketplace Custom model import

평가

Programmatic Human RAG LLM 심사

대규모 추론

유연한 옵션

On demand Provisioned throughput Batch

추론 최적화

프롬프트 캐싱 지능형 프롬프트 라우팅 지연 시간 최적화 추론

글로벌 확장성

전 세계 리전 교차 리전 추론

가드 레일

Amazon Bedrock에서 제공하는 모델들

선도 AI 기업들과의 파트너십을 통해 다양한 모델 제공

AI21labs

긴 컨텍스트에서 고효율 처리 및 근거 기반 생성

JAMBA

amazon

최첨단 지능과 업계 최고의 가격 대비 성능

NOVA

ANTHROPIC

복잡한 추론, 코드 생성, 지시 따르기에 탁월

CLAUDE

cohere

고급 검색 기능을 갖춘 효율적인 다국어 AI 에이전트 지원

COMMAND
EMBED
RERANK

deepseek

복잡한 문제를 단계별로 해결하는 고급 추론 모델

DEEPSEEK

Luma

자연스럽고 일관된 모션과 초현실적 디테일의 고품질 동영상 생성

RAY

Meta

고급 이미지 및 언어 추론

LLAMA

MISTRAL AI

에이전틱 추론 및 멀티모달 작업을 위한 전문 모델

MISTRAL
MIXTRAL
PIXTRAL

OpenAI

작업 자동화, 창의성 향상, 복잡한 문제를 효율적으로 해결

GPT-OSS

Qwen

에이전틱 지능을 활용한 고급 추론

QWEN

stability.ai

크리에이티브 제어가 가능한 전문가급 이미지, 대규모 배포 가능

STABLE DIFFUSION
STABLE IMAGE

TwelveLabs

비디오 데이터를 위한 CTRL+F: 기업 비디오 자산의 잠재력 완전 활용

MARENGO
PEGASUS


WRITER

기업 전반의 AI 에이전트 구축 및 확장을 위한 전용 모델


PALMYRA

파운데이션 모델의 분류


모델에서 생성 가능한 출력을 기반으로 크게 5가지 종류로 구분



Amazon Bedrock 파운데이션 모델의 생명 주기



Amazon Bedrock으로 모델 접근하기




Amazon Bedrock 관리 콘솔 – Playground


관리 콘솔에서 파운데이션 모델을 호출 및 테스트

파라미터 및 설정 튜닝:

- 모델 변경/선택
- 추론 파라미터 설정
- 시스템 프롬프트
- 추론 모드
- 출력 토큰 수
- 가드레일 등



에이전트 개발자 도구와 Amazon Bedrock 연동



Amazon Bedrock API

Bedrock 네이티브 API

(*bedrock-runtime* 엔드포인트)

- **Invoke:** 모델 직접 호출
- **Converse:** 채팅 지원 모델을 위한 통합 API

Anthropic/OpenAI 호환 API

(*bedrock-mantle* 엔드포인트)

- **Responses:** OpenAI 호환 (Stateful)
- **Chat completions*:** OpenAI 호환 (Stateless)
- **Messages*:** Anthropic 호환

* *bedrock-runtime* 엔드 포인트에서도 호환



AWS 도구 및 SDK
(Python, JS, JAVA, Go..)



AWS 명령줄 인터페이스(AWS
CLI)






ANTHROPIC
OpenAI

Anthropic /
OpenAI SDKs
(*bedrock-mantle* 엔드포인트 사용)

최적화를 위한 다양한 옵션

추론 수준

기능 수준



서비스 티어:



우선순위 (Priority)



표준 (Standard)



플렉스 (Flex)



예약 (Reserved)



배치 (Batch)

리전 옵션:



리전 내



교차 리전

최적화 옵션:



모델 종류



지능형 프롬프트 라우팅




프롬프트 캐싱

Amazon Bedrock 서비스 티어

프롬프트는 각 티어에
해당하는 큐에 배치


Priority 중요한 작업에 필요한 가장 빠른 응답 시간 제공




Standard 일상적인 작업에 필요한 일관된 성능 제공



Flex 비용 효율적인 작업에 적합하며, 긴 처리 시간이 허용되는 워크로드



티어에 따라
스케줄링



Bedrock Model

모델 추론 엔드포인트




Bedrock API 요청 시, 프롬프트와
함께 서비스 티어 명시

```
service_tier = "reserved" | "priority" | "default" | "flex"
```




Amazon Bedrock 파운데이션 모델 맞춤화



프롬프트
엔지니어링



검색 증강 생성
(RAG)



미세 조정
(Fine tune)





지속적 사전 훈련
(Pre-training
job)

복잡성 • 품질 • 비용 • 시간

Amazon Bedrock 프롬프트 관리

생성형 AI 애플리케이션 개발을 간소화



- Amazon Bedrock 콘솔 및 SDK API에 내장된 프롬프트 빌더
- 간편한 카탈로그 작성 및 관리를 위한 프롬프트 라이브러리

- Bedrock Flow와의 원활한 통합

Amazon Bedrock 지식 기반


검색 증강 생성(Retrieval Augmented Generation, RAG) 지원

파운데이션 모델을
데이터 소스에
안전하게 연결,
RAG로 더 관련성 높은
응답 제공

수집, 검색 및
증강을 포함한
완전 관리형 RAG
워크플로우

멀티턴 대화를 위한
내장 세션 컨텍스트
관리

투명성 향상을 위한
검색 기반 자동 인용



Amazon Bedrock 지식 기반

네이티브 혹은 벡터 검색이 지원되는 데이터베이스 선택

BEDROCK 네이티브 지식 기반:



Amazon OpenSearch
Serverless용 벡터 엔진



Amazon Aurora
PostgreSQL
(pgvector)



Pinecone



Redis
Enterprise
Cloud



MongoDB

벡터 검색을 지원하는 AMAZON 데이터베이스:



Amazon
OpenSearch
Serverless



Amazon
OpenSearch
Service



Amazon
Aurora
PostgreSQL



Amazon RDS
PostgreSQL



Amazon
DynamoDB
via zero-ETL



Amazon
MemoryDB




Amazon
Neptune



Amazon
DocumentDB

검색 증강 생성(RAG) 워크플로우



Amazon Bedrock Knowledge Base > 데이터 적재

완전 관리형
데이터 수집
워크플로우



데이터 소스

- 다양한 데이터 소스
- 증분 업데이트
- 메타데이터 지원
- 멀티모달 지원

Choose data source type

Select the data source type that you want to configure in the next step. You may add additional data sources once your Knowledge Base is created.



Amazon S3

Object storage service that stores data as objects within general purpose buckets. Add up to 5 buckets as data sources.



Confluence - Preview

Collaborative work-management tool designed for project planning, software development and product management.



Custom

Create a data source directly in Amazon Bedrock. A custom data source allows the flexibility to automatically ingest documents into your vector database directly.



Salesforce - Preview

Customer relationship management (CRM) tool for managing support, sales, and marketing data.



Sharepoint - Preview

Collaborative web-based service for working on documents, web pages, web sites, lists, and more.




Web Crawler - Preview

Web page crawler that extracts content from public web pages you are authorized to crawl.



Amazon Bedrock Knowledge Base > 데이터 적재

완전 관리형
데이터 수집
워크플로우



- 다양한 파일 포맷 지원 (.pdf, .doc, .docx, .csv, .xlsx, .md, .html 등)
- 텍스트 기반 파싱
- LLM 기반 파싱

Parsing strategy [Info](#)

The Amazon Bedrock Default parser handles common text formats, while specialized parsers are needed for other content types according to the chosen embedding model's capabilities.

Amazon Bedrock default parser

Best if only parsing text. This parser will ignore multimodal content. Commonly used with multimodal embedding model.

Data parsed:

- Text documents(e.g. Word, Excel, html, markdown, .txt, .csv)

Parser output:

- Extracted text

Amazon Bedrock Data Automation as parser

Allows you to parse text and store multimodal content as text. Use this for high accuracy speech retrieval on audio/video files.

Data parsed:

- PDFs
- Images
- Audio
- Video

Parser output:

- Extracted text
- Descriptions for images, visuals, figures, charts
- Transcription for audio/video
- Video summarization

Amazon Bedrock Knowledge Base > 데이터 적재

완전 관리형
데이터 수집
워크플로우



청킹 전략 선택

- Default
- Hierarchical
- Semantic
- Custom chunking

Default chunking

By default, knowledge base automatically splits your source data into chunks each containing, at most, 300 tokens. If a document contains less than 300 tokens, then it is not split any further. ✓

Fixed-size chunking

Amazon Bedrock splits your text into chunks of approximately fixed size.

Hierarchical chunking

Divides nodes into hierarchical structures, resulting in multiple hierarchies of various chunk sizes from a single input. Each node includes a reference to its parent node.

Semantic chunking


Extracts semantic meaning from embeddings and then assess the semantic relationship between these chunks. Keeps together chunks that are semantically similar.

No chunking

This option is suitable if you have pre-processed your documents by splitting them into separate files and do not want Bedrock to further chunk your documents.

Amazon Bedrock Knowledge Base > 데이터 적재

완전 관리형
데이터 수집
워크플로우



- 임베딩 모델 선택
 - Amazon Titan
 - Cohere

Embeddings model

Select an embeddings model to convert your data into an embedding. Pricing depends on the model. [Learn more](#)

 [Titan Text Embeddings v2](#) 
By Amazon

 [Titan Embeddings G1 - Text v1.2](#) 
By Amazon


 [Embed English v3](#) 
By Cohere

 [Embed Multilingual v3](#) 
By Cohere



Amazon Bedrock Knowledge Base > 데이터 적재

완전 관리형
데이터 수집
워크플로우




벡터 스토어 선택

- Amazon OpenSearch Serverless용 벡터 엔진
- Amazon Aurora PostgreSQL
- pgvector
- MongoDB
- Pinecone
- Redis Enterprise Cloud




© 2026, Amazon Web Services, Inc. or its affiliates.




Amazon Bedrock Knowledge Base > 데이터 조회/쿼리

완전 관리형
검색 증강
생성 (RAG)




사용자 지정 RAG 워크플로우




Amazon Bedrock 가드레일

AI 애플리케이션의 취약성



Amazon Bedrock 가드레일

AI 애플리케이션을 위한 안전 장치 필요





Amazon Bedrock Guardrails

프롬프트 및 모델 응답 평가
모든 모델에 적용 가능



컨텐츠 필터를 사용한 컨텐츠 검토



거부된 주제/토픽 기반의 주제 분류



민감정보 필터를 사용한 개인정보 삭제



단어 필터링을 통한 특정 단어 필터링



컨텍스트 근거 확인을 통한 할루시네이션 대응



자동화된 추론 확인을 통한 사실 검증

Web Services, Inc. or its affiliates.

Amazon Bedrock 에이전트



01

파운데이션 모델 선택




02

기본 지시사항 제공



03


관련 데이터 소스 선택



04

사용 가능한 액션 지정

- 작업을 생성 및 분류하고 오케이스트레이션
- 검색 증강 생성을 위한 사용자 데이터에 안전하게 접근
- 사용자 대신 API 호출하여 행동을 수행
- 사고 과정 추적 및 에이전트 프롬프트 수정 기능



Amazon Bedrock 에이전트 소개



Amazon Bedrock 에서 AI Agent를 구성하기 위한 옵션



Amazon Bedrock 에이전트

- 정식 생성, 준비, 별칭, 호출 패턴
- 모델, 지시사항 정의
- 지식 기반, 액션 그룹, 메모리, 가드레일 추가

Amazon Bedrock 인라인 에이전트

- 동적 구성
- InvokeInlineAgent API
- 모델, 지시사항, 지식 기반, 액션 그룹, 메모리, 가드레일을 즉시 변경 가능

Amazon Bedrock AgentCore

- 모듈형 프레임워크
 - 런타임 및 ID
 - Code Interpreter, Browser, Gateway 도구 제공
 - Memory
 - 관측성
- Knowledge bases and guardrails



Thank you!